Introducción a la ciencia de datos

Estimador de precios de viviendas

Del primer modelo lineal a XGBoost optimizado con Optuna, explicado con Feature Importance y SHAP.

4,546 ventas reales

XGBoost + Optuna

Error típico 10,9 %



INTEGRANTES

Xiomy Baquero Morales
Michael Román Álzate

Universidad de Medellín
Especialización en ciencia de datos e inteligencia artificial

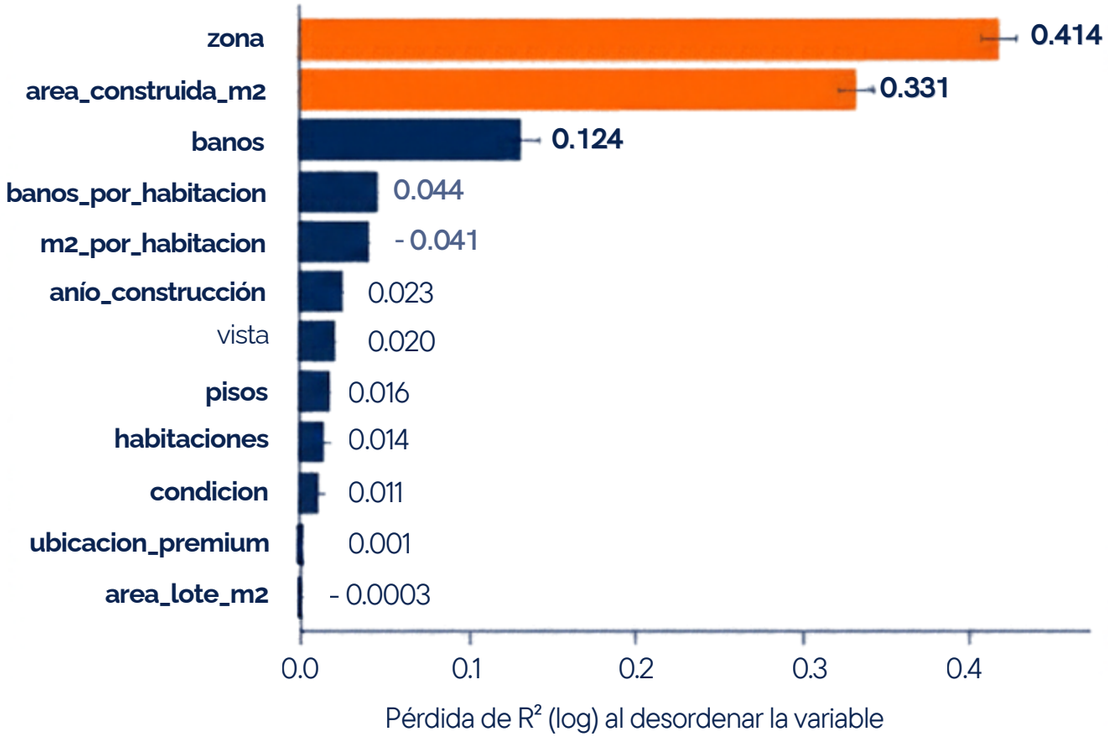
Medellín, 2026.

Fuga, deriva y correcciones

Validamos la información, revisamos las variables más relevantes y corregimos los problemas antes de entrenar XGBoost.

Importancia por permutación – M2

(caída del R^2 log al desordenar cada variable)



DATA LEAKAGE

Detectado y corregido

Se excluyó precio_por soft por estar derivado del precio objetivo.

R^2 log
0.72 → 0.97

Al incluir la variable derivada del precio.

DATA DRIFT

Sin deriva relevante

Datos de 2014; no garantizan estabilidad del mercado actual.

PSI máximo
< 0.03
en todas las variables revisadas.

CORRECCIONES

Datos más limpios

- Exclusión de variables derivadas del objetivo.
- Revisión de variables redundantes (p. ej., ubicación premium con vista).
- Separación de evaluación y selección de hiperparametros.



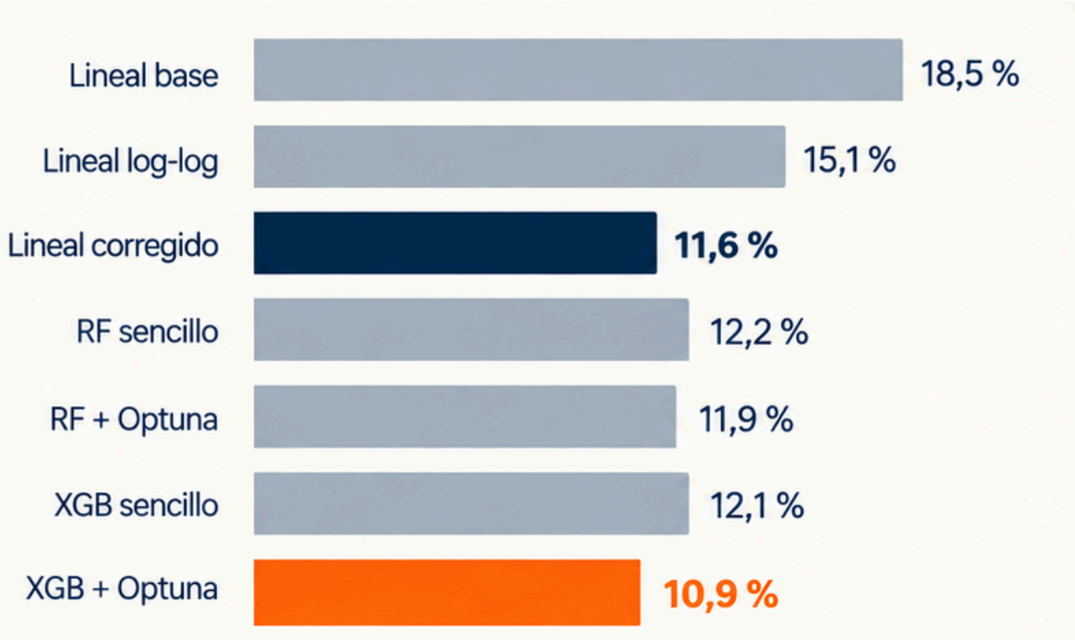
Conclusión: Se detectó y corrigió la fuga de datos, no se observó deriva relevante en las comparaciones realizadas y se revisaron variables redundantes. El modelo queda listo para entrenar XGBoost y optimizar con Optuna.

Del modelo simple al mejor modelo

Comparación de modelos y desempeño del modelo final con XGBoost + Optuna.

Evolución del error

Error porcentual mediano (MedAPE)



Error porcentual mediano

10,86 %

Menor error entre todos los modelos.

R^2 logarítmico

0,842

Buen ajuste del modelo en escala logarítmica.

MAE

US$ 84.518

Error absoluto medio en dólares.

Predicciones dentro de ±20 %

75,9 %

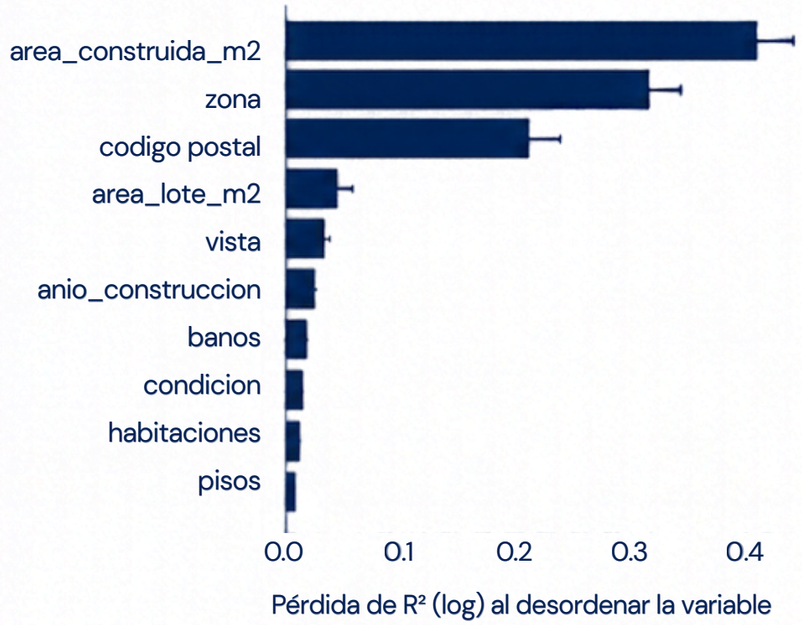
Proporción de predicciones con error menor al 20 %.

Conclusión: XGBoost + Optuna alcanzó el menor error porcentual mediano **(10,86 %)** y un buen ajuste del modelo, mejorando el desempeño frente a otros enfoques.

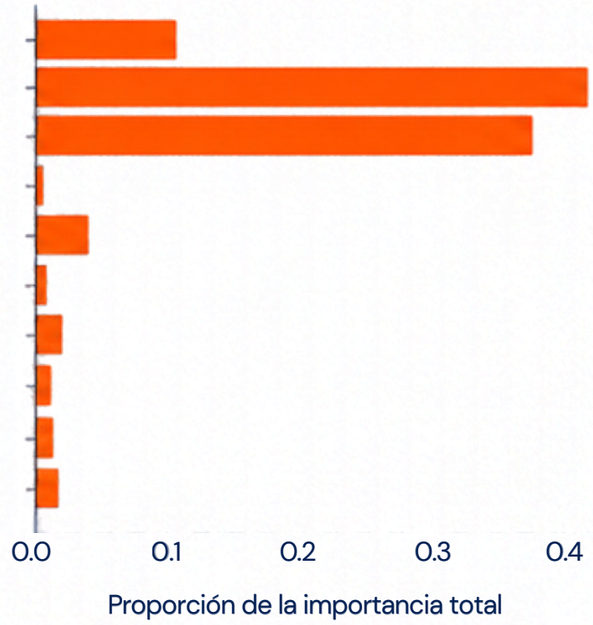
Feature Importance
las variables más relevantes

Dos métodos de importancia permiten analizar qué variables utiliza XGBoost para estimar los precios.

Importancia por permutación
(caída del R^2 log al desordenar cada variable)



Importancia nativa de XGBoost
(proporción de la importancia total)



Área construida

Es una de las variables con mayor importancia predictiva. Las viviendas de mayor área suelen recibir precios estimados más altos.

Zona y código postal

Capturan diferencias de ubicación que ayudan a distinguir los precios entre viviendas. Tienen alta relevancia en ambos métodos.

Otros factores

Área del lote, vista, baños y año de construcción también contribuyen a las predicciones, aunque con menor importancia relativa.

¿Por qué dos métodos?

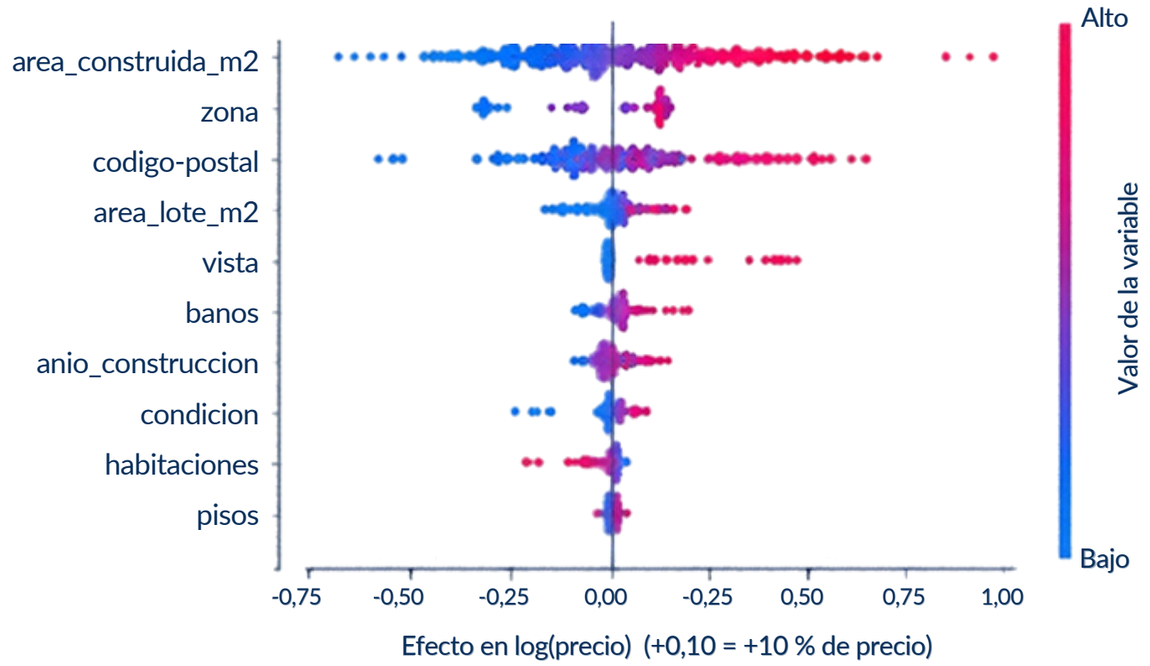
La importancia por permutación mide cuánto empeora el modelo al desordenar una variable, mientras que la importancia nativa refleja los criterios internos de los árboles de XGBoost.

El modelo se comporta de forma razonable

SHAP nos muestra cómo cada variable influye en las predicciones del precio.

Resumen de impacto de variables (SHAP)

Cada punto representa una vivienda. El color indica el valor de la variable (rojo = alto, azul = bajo).



1 Área construida

Es la variable con mayor impacto. Los valores altos tienden a aumentar el precio predicho.

2 Zona y código postal

También tienen un peso importante. Pueden aumentar o disminuir el precio, dependiendo de la ubicación.

(variables codificadas)

3 Vista, baños y año de construcción

Contribuyen a las predicciones, aunque su impacto es menor que el área construida y la ubicación.

4 Habitaciones y pisos

Presentan un impacto relativo menor, con valores más cercanos a cero.

